



RAG

朱克剛

RAG – 檢索增強生成


- 透過外部檢索，讓語言模型回答原本不知道的知識
- 不修改語言模型權重，因此速度非常快

問：世界上最美的女人是誰？


答：白雪公主

問：魔鏡的主人是誰？

答：壞皇后



語意向量





嵌入模型

- BGE / 開源模型 / 北京智源人工智能研究院
 - 可在 ollama 中安裝，CPU 可跑，n8n 可讀取使用
 - <https://ollama.com/quentinz/bge-large-zh-v1.5>
 - 中文處理精度極佳
- text-embedding-3-small / 付費使用 / OpenAI
 - 中文處理佳
- text-embedding-004 / 付費使用（有免費額度） / Google
 - 中文處理極差

起手式

■ 文章形式 - 科幻小說

- <https://raw.githubusercontent.com/kiarkchu/mongodb/refs/heads/main/ai/space.txt>



換成 Postgres 向量資料庫

host: host.docker.internal
database: postgres
user: postgres
password: <your_password>
ssl: disable
port 5432

DO \$\$

BEGIN

IF EXISTS (

SELECT 1

FROM information_schema.tables

WHERE table_schema = 'public'

AND table_name = 'n8n_vectors'

) THEN

TRUNCATE TABLE "n8n_vectors"

END IF;


END;

\$\$;

朱克剛

n8n - Line 機器人與RAG


資料表名稱可修改



向量資料庫內容


	id	text	metadata	embedding
1	be707206-fbd1	《恆星之外的旅途》 111 太	{"loc": {"lines": {"to": 47, "from": 1}}}	[0.023575893,0.023399293,-0.027
2	7a34f256-00fc	阿嵐冒險將「晨曦號」的重	{"loc": {"lines": {"to": 83, "from": 37}}}	[0.016591324,0.033078432,-0.042
3	1fc5b4ba-4fcb	沃爾克沉默很久，最後緩	{"loc": {"lines": {"to": 101, "from": 73}}}	[0.027915927,0.009828778,-0.0586

資料來源為 PDF



資料為 Q&A 型式

- 星聯科技公司：
<https://github.com/kirkchu/mongodb/blob/main/ai/qa.json>
- 也可以將 Q&A 存在 Google Sheet 中，讀出也是 JSON 格式



Default Data Loader

Parameters Settings Docs

Type of Data
JSON

Mode
Load Specific Data

Data
fx {{ \$json.question }}

星聯科技的上下班時間是幾點？

Text Splitting
Simple

Options
Metadata

Name
answer


Value
fx {{ \$json.answer }}

我們採彈性上下班，核心時段為 10:00 至 1...

Microsoft PowerPoint


模型種類與記憶節點

- 語言模型與嵌入模型可以不同公司開發的模型，但儲存與查詢必須使用同一種嵌入模型
- 當向量資料庫資料更新後，Simple Memory 有時不會清除舊資料，刪除重拉一次就可以了



兩階段檢索

兩階段檢索增強生成 (RAG) 流程圖




Reranker

- Reranker 計算問題與各答案間的關連性（邏輯性），然後給出分數最好的答案。目的是用來增加回應精準度
- 查詢簡短模糊：使用者喜歡問「費用？」、「怎麼辦？」這種超短問題，向量搜尋很難抓到意圖
- 複雜邏輯查詢：使用者問「比較 A 和 B 的不同」或「在 X 情況下，如果 Y 發生了該怎麼做？」這種需要多層次推理的問題
- Reranker 的作法是先透過嵌入向量搜尋出候選答案，然後再透過 reranker 去計算問題與答案間的關連性
- 可以增加精準度，但犧牲回應時間

新增 Reranker 節點

- 社群節點：n8n-nodes-ollama-reranker
- Ollama 安裝模型指令：`ollama pull dengcao/bge-reranker-v2-m3`



練習

- 將 RAG 整合進 Line 機器人